

Prediccion de Calidad del Vino

Wine Quality Prediction - Clasificacion con Machine Learning

Marco Brante

Bootcamp Data Science - Skillnest / Sonda

Core 12 | Junio 2026

1. Introduccion

Este proyecto aplica tecnicas de clasificacion supervisada para predecir la calidad de vinos tintos a partir de sus caracteristicas fisico-quimicas. El conjunto de datos utilizado es el Wine Quality Dataset (Kaggle), con 1.143 muestras, 11 variables predictoras y una variable objetivo (quality) en escala 0-10. El objetivo es identificar que modelo de Machine Learning ofrece mejor rendimiento, analizando el impacto del desbalance de clases y justificando cada decision de preprocesamiento con base en el analisis exploratorio.

1.1 Variables del Dataset

Variable	Nombre	Descripcion
<i>fixed acidity</i>	Acidez fija	Acidez fija del vino (acido tartarico). Influye en sabor y estabilidad.
<i>volatile acidity</i>	Acidez volatil	Acido acetico; niveles altos producen sabor avinagrado.
<i>citric acid</i>	Acido citrico	Anade frescura al vino en pequenas cantidades.
<i>residual sugar</i>	Azucar residual	Azucar que queda tras la fermentacion.
<i>chlorides</i>	Cloruros	Cantidad de sal en el vino.
<i>free sulfur dioxide</i>	SO2 libre	Previene oxidacion y crecimiento microbiano.
<i>total sulfur dioxide</i>	SO2 total	Suma de SO2 libre y ligado.
<i>density</i>	Densidad	Densidad del vino; depende del alcohol y azucar.
<i>pH</i>	pH	Nivel de acidez/basicidad (escala 0-14).
<i>sulphates</i>	Sulfatos	Antimicrobiano y antioxidante.
<i>alcohol</i>	Alcohol	Porcentaje de contenido alcoholico.
<i>quality</i>	Calidad (target)	Puntuacion sensorial 0-10. Variable objetivo.

2. Exploracion y Analisis de Datos

2.1 Estructura del Dataset

El dataset cuenta con 1.143 registros y 12 columnas (11 predictoras + 1 objetivo). No se encontraron valores nulos. Se elimino la columna Id por no aportar informacion predictiva.

2.2 Distribucion de la Variable Objetivo

La variable quality presenta un fuerte desbalance de clases. Las calidades 5 y 6 concentran el 82.7% del total, mientras que los extremos suman apenas el 4.8%:

Calidad	Frecuencia	Porcentaje
3	6	0.5%
4	33	2.9%
5	483	42.3%
6	462	40.4%
7	143	12.5%
8	16	1.4%
TOTAL	1.143	100%

Implicacion: un modelo que predijera "calidad 5 o 6" para todo tendria ~83% de accuracy sin aprender nada util. El accuracy global es una metrica engañosa para este problema por eso se priorizara el F1-Score por clase.

2.3 Distribucion de Variables Fisico-Quimicas

Se identificaron tres patrones de distribucion en las variables predictoras:

- **Distribucion aproximadamente normal:** pH (mas simetrica, pico en ~3.3), density (rango estrecho: 0.990-1.004) y fixed acidity (pico en ~7-8).
- **Sesgo pronunciado a la derecha:** residual sugar, chlorides, free SO2 y total SO2 — masa concentrada en valores bajos con colas largas. Las mas afectadas por outliers.
- **Distribucion irregular:** citric acid presenta pico inusual en 0 (vinos sin acido citrico anadido — comportamiento real del proceso). Alcohol con pico en ~9.5% y distribucion irregular.

2.4 Analisis de Outliers (Metodo IQR)

Cuantificacion de outliers mediante rango intercuartilico (IQR). Las variables mas afectadas:

Variable	Outliers	%	Severidad
residual sugar	110	9.6%	Alta
chlorides	77	6.7%	Alta
fixed acidity	44	3.8%	Moderada
sulphates	43	3.8%	Moderada
total sulfur dioxide	40	3.5%	Moderada
density	36	3.1%	Moderada

citric acid	1	0.1%	Minima
-------------	---	------	--------

Observacion: density es la unica variable con outliers en ambos extremos, llamativo dado su rango muy estrecho. total sulfur dioxide presenta un outlier extremo cercano a 290 cuando la caja se concentra entre 20-60.

2.5 Correlaciones con la Variable Objetivo

Las correlaciones de Pearson revelaron las relaciones mas relevantes:

Variable	Correlacion	Interpretacion
alcohol	+0.48	Mayor alcohol → mejor calidad. La relacion mas fuerte del dataset.
volatile acidity	-0.41	Mayor acidez volatil → peor calidad (sabor avinagrado).
sulphates	+0.26	Efecto conservante positivo moderado.
citric acid	+0.24	Frescura — efecto positivo moderado.
total SO2	-0.18	Efecto negativo leve en altas concentraciones.
density	-0.18	Alta densidad → menor alcohol → menor calidad.
residual sugar	+0.02	Sin relacion relevante con quality en vinos tintos.

Multicolinealidad detectada: fixed acidity con pH (-0.69), fixed acidity con density (+0.68), y free SO2 con total SO2 (+0.66). Esto no afecta a Random Forest ni KNN, pero puede impactar la interpretabilidad de la Regresion Logistica.

3. Preprocesamiento de Datos

3.1 Tratamiento de Outliers — Capping (Winsorizing)

Se descarto la eliminacion de registros y se opto por Capping al percentil 1%-99%, que recorta valores extremos al limite definido sin eliminar filas. Razones:

- **Tamano del dataset:** con solo 1.143 registros, eliminar los 110 outliers de residual sugar significaria perder el 9.6% de los datos.
- **Naturaleza de los datos:** los valores extremos son mediciones reales de vinos con características inusuales, no errores de captura.
- **Sin perdida de informacion:** el capping conserva todos los registros reduciendo el efecto distorsionador de los outliers.

3.2 Agrupacion del Target en 3 Clases

Las clases 3 y 4 contaban con apenas 6 y 33 muestras (3.4% total). Con 6 etiquetas donde dos tienen menos del 3% de representacion, los modelos nunca predicen correctamente las clases minoritarias. Se agruparon en 3 categorias:

Clase	Calidades	Muestras	Porcentaje
Baja (0)	quality <= 4	39	3.4%
Media (1)	quality 5 o 6	945	82.7%
Alta (2)	quality >= 7	159	13.9%

3.3 Division y Escalado

- **Train/Test Split 80/20 estratificado (stratify=y):** garantiza que la proporcion de cada clase se mantenga en ambos conjuntos. Sin estratificacion, la clase Baja (39 muestras) podria quedar subrepresentada en prueba.
- **StandardScaler:** variables con escalas muy distintas (total SO2 llega a 289; density varia en 0.990-1.004). El scaler se ajusta solo con datos de entrenamiento y se aplica a prueba, evitando data leakage.

4. Entrenamiento de Modelos

Se entrenaron tres modelos con optimización de hiperparametros mediante GridSearchCV + StratifiedKFold (k=5), usando F1-Score weighted como metrica de seleccion:

Modelo	Hiperparametros evaluados	Mejor configuracion
K-Nearest Neighbors	n_neighbors: [3, 5, 7, 9, 11, 15]	n_neighbors = 5
Random Forest	n_estimators: [100,200] / max_depth: [None,10,20] / min_samples_split: [2,5]	n_estimators=200, max_depth=None
Regresion Logistica	C: [0.01, 0.1, 1, 10] / solver: [lbfgs, saga]	C=1, solver=lbfgs

5. Resultados y Evaluacion

5.1 Metricas Globales

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.908 *	0.876	0.908	0.889 *
KNN	0.869	0.832	0.869	0.847
Regresion Logistica	0.847	0.804	0.847	0.819

5.2 Analisis por Clase — Matrices de Confusion

Las matrices de confusion revelan el comportamiento real de cada modelo por clase, mas informativo que el accuracy global dado el desbalance:

Clase	KNN (recall)	Random Forest (recall)	Reg. Logistica (recall)
Baja (0)	0% — 0/8	0% — 0/8	0% — 0/8
Media (1)	96.3% — 182/189	98.4% — 186/189 *	96.3% — 182/189
Alta (2)	53.1% — 17/32	68.8% — 22/32 *	37.5% — 12/32

Hallazgo critico: ningun modelo predice correctamente la clase Baja. Las 8 muestras de prueba son clasificadas como Media en los tres casos. Esto es consecuencia del desbalance extremo (solo 39 muestras = 3.4%). La diferencia clave entre modelos esta en la clase Alta: RF logra 69% recall vs 38% de Regresion Logistica.

5.3 Curva ROC — Random Forest (One-vs-Rest)

La curva ROC muestra la capacidad discriminativa por clase usando la estrategia One-vs-Rest:

Clase	AUC estimado	Interpretacion
Alta (2)	~0.92	Excelente separacion — identifica bien los vinos de alta calidad.
Media (1)	~0.87	Buena capacidad — frontera mas difusa por ser la clase dominante.
Baja (0)	~0.75	Aceptable en probabilidad, pero insuficiente para cruzar el umbral de clasificacion.

Todos los AUC superan significativamente el 0.50 (clasificador aleatorio), confirmando que Random Forest tiene capacidad predictiva real en los tres escenarios.

5.4 Importancia de Caracteristicas

Random Forest identifico las variables mas determinantes para la prediccion de calidad:

#	Variable	Importancia	Relacion con quality
1°	alcohol	Alta	+0.48 (correlacion mas fuerte)
2°	volatile acidity	Alta	-0.41 (penaliza la calidad)
3°	sulphates	Media-Alta	+0.26 (efecto conservante)
4°	citric acid	Media	+0.24 (frescura)
5°	density	Media	-0.18 (proxy inverso del alcohol)

...	residual sugar	Baja	+0.02 (sin relevancia practica)
-----	----------------	------	---------------------------------

6. Comparacion de Modelos

Modelo	Fortalezas	Debilidades
KNN	Simple, sin supuestos parametricos, facil de interpretar. Resultados intermedios aceptables.	Sensible a la escala, lento en prediccion. Recall bajo en clase Alta (53%).
Random Forest	Mejor rendimiento general. Robusto a outliers. Mejor recall en clase Alta (69%). Proporciona importancia de caracteristicas.	Menos interpretable. Mayor tiempo de entrenamiento.
Regresion Logistica	Mas interpretable. Rapido de entrenar.	Peor recall en clase Alta (38%). La relacion entre variables y calidad no es lineal.

7. Conclusiones

Random Forest es el modelo recomendado para este problema por las siguientes razones:

- **Mejor rendimiento global:** Accuracy 0.908 y F1-Score 0.889, superando a KNN (0.847) y Regresion Logistica (0.819).
- **Mejor manejo del desbalance:** su recall en clase Alta es 69% vs 53% (KNN) y 38% (Regresion Logistica).
- **No requiere linealidad:** la relacion entre caracteristicas fisico-quimicas y calidad no es lineal — esto penaliza directamente a la Regresion Logistica.
- **Variables determinantes identificadas:** alcohol, volatile acidity y sulphates son los factores mas importantes, consistente con el analisis de correlaciones.

Limitacion principal: ningun modelo logro predecir la clase Baja. Con solo 39 muestras de entrenamiento (3.4%), el desbalance es demasiado extremo. Para mejorar esto en trabajos futuros se podria aplicar SMOTE (Synthetic Minority Oversampling Technique) o usar `class_weight="balanced"` en los modelos.